

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ

ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ  
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ  
МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ  
(ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ)

ФАКУЛЬТЕТ ИННОВАЦИЙ И ВЫСОКИХ ТЕХНОЛОГИЙ  
КАФЕДРА КОМПЬЮТЕРНОЙ ЛИНГВИСТИКИ

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА  
(БАКАЛАВРСКАЯ РАБОТА)

по направлению 01.03.02 «Прикладная математика и информатика»

# Японский. Буквенные n-граммы для распознавания

Студент

Куликов А.В.

Научный руководитель

Андрианов А.И.

Москва, 2017

# Оглавление

Введение . . . . .	3
1 Постановка задачи . . . . .	4
1.1 Обзор японского языка . . . . .	5
1.2 Путающиеся символы в японском . . . . .	7
1.3 Формальная постановка задачи . . . . .	8
2 Обзор источников . . . . .	10
3 Описание моделей оценивания текста . . . . .	11
3.1 $N$ -граммные модели с фиксированным $n$ . . . . .	11
3.2 Backoff-модель . . . . .	12
3.3 Модель Катца (Katz) . . . . .	12
3.4 <b>TODO: Maybe Kneser-Ney</b> . . . . .	12
4 Описание эксперимента . . . . .	13
4.1 <b>TODO: Описание машины – надо ли?</b> . . . . .	13
4.2 Корпус . . . . .	13
4.3 <b>TODO: Zipf</b> . . . . .	14
4.4 Генератор шума и режимы его работы . . . . .	15
4.5 Baseline . . . . .	16
4.6 Пример работы и статистик . . . . .	16
5 Реализация модели . . . . .	17
5.1 nltk, Python, избранные куски кода в приложение? . . . . .	17
6 Результаты эксперимента . . . . .	18
7 Анализ результатов . . . . .	19
8 Заключение . . . . .	20
Список литературы . . . . .	21

# Введение

История попыток распознать текст началась более века назад. В 1914 году Эмануэль Гольдберг разработал устройство, который считывало символы и транслировало их в телеграфный код. Примерно в то же время ирландский химик Эдмунд Фурнье д'Альбе создал и запатентовал «оптофон» — прибор, умеющий переводить написанное в систему звуков, различающихся по высоте. Оптофон предназначался для того, чтобы слепые могли «читать».

В 1929 году Густав Таушек (Gustav Tauschek) разработал метод оптического распознавания текста. Машина Таушека представляла собой механическое устройство, которое использовало шрифтовые шаблоны и фотодетектор. Он запатентовал своё изобретение сначала в Германии, а позднее и в США, в 1935 году. Это и положило начало проблеме качественного оптического распознавания символов (Optical Character Recognition, OCR).

Коммерческое производство подобных машин было налажено уже в 1950-х, после войны. Используя наработки военных, производители OCR-машин продвигались всё дальше, увеличивая применимость технологии и качество распознавания.

Постепенно появлялись как универсальные OCR-программы (ABBYY FineReader, Adobe Acrobat), так и специализированные для конкретной области (SmartScore для нотной записи, Persian Reader для фарси и т.д.). При этом точность в задаче распознавания напечатанных латинских символов достигла 99%-100% качества, в то время как корректное распознавание рукописного текста или текста, написанного в другом алфавите, до сих пор является темой множества исследований. Особняком стоит задача распознавания текста на восточных языках (китайский, японский, корейский, ...), из-за большого размера алфавита в этих языках.

Настоящая работа представляет собой сравнение некоторых методов машинного обучения для исправления ошибок распознавания текста в японском языке.

Спектр способов, которыми можно решать проблему автоматического

исправления ошибок, довольно широк, и включает в себя различные вариации  $n$ -граммных методов ( $n$ -gram models), использование нейросетей (Neural Networks, NN), скрытых моделей Маркова (Hidden Markov Models, НММ) и прочих методов машинного обучения. Более подробный обзор основных современных подходов можно найти в [1].

Среди возможных решений использование  $n$ -граммных моделей занимает особую нишу из-за относительной прозрачности и интуитивности принципов работы, и в то же время достаточно широких возможностей по настройке алгоритма.

Подход, предложенный в [2], использует  $n$ -граммные модели, а также различные алгоритмы сглаживания для исправления опечаток, опираясь на словное деление текста.

В работе [3] также даются эвристики для определения границ слов, использующие граф линейного деления (ГЛД). Эти границы слов затем используются в  $n$ -граммной модели в качестве вспомогательного контекста.

Более подробно эти и другие подходы разобраны в соответствующем разделе (2).

Данное исследование призвано рассмотреть некоторые из  $n$ -граммных моделей и сравнить их эффективность в задаче исправления опечаток в японском языке.

Актуальным приложением этой работы является система распознавания восточных языков в ABBYY FineReader.

## 1 Постановка задачи

**Определение 1.0.1.** *Оптическое распознавание символов (Optical Character Recognition, OCR)* – процесс считывания текста с физического носителя и его сохранения в цифровом формате. Текст состоит из *символов*.

**Определение 1.0.2.** *Ошибка OCR* – случай, когда очередной символ текста распознан неверно или не распознан. Ведёт к понижению качества распознавания.

**Определение 1.0.3.** *N-грамма* – последовательность из  $n$  элементов (слов, звуков, символов). Анализируя их частотности, можно строить модели для анализа и синтеза языка.

**Определение 1.0.4.** *N-граммная модель* – вероятностная модель языка, которая рассчитывает вероятность последнего элемента  $n$ -граммы, если известны все предыдущие.

При использовании  $n$ -граммных моделей предполагается, что появление каждого элемента зависит только от предыдущих элементов.

**Цель работы** – сравнить эффективность различных символьных  $n$ -граммных моделей в задаче исправления ошибок OCR в японском языке.

Из цели работы вытекают следующие **задачи**:

- Рассмотреть существующие подходы к  $n$ -граммному моделированию японского языка;
- Реализовать некоторые модели;
- Развернуть систему для тестирования и сравнения моделей.

Чтобы понять специфику цели работы, нужно учесть особенности японского языка.

Очевидно, что устройство японского языка на уровне конкретных символов сложнее, чем устройство языков латино-романской группы (в которых существует всего 25-40 символов, учитывая возможную диакритику).

## 1.1 Обзор японского языка

Письменный японский текст – это комбинация слогово-фонетических символов (кана) и иероглифов (кандзи). Слоговая азбука кана делится на катакану и хирагану, которые представляют собой разные графические формы одних и тех же слогов. **TODO: сказать, почему забиваем на окуригану и т.д.**

Рассмотрим эти символы подробнее:

- Хирагана (см. Рис. 1), символы более округлые, чем в катакане. В основном используется для образования грамматических морфем.




Рис. 1: hirag\_sample

- Катакана (см. Рис. 2), символы более резкие, чем в хирагане. Используется для транскрибирования иностранных заимствованных слов **TODO: примеры :).**




Рис. 2: katak\_sample

- Также есть диакритические символы – дакутен, хандакутен (**TODO: ?**) (см. Рис. 3). Они могут применяться как к катакане, так и к хирагане, и определённым образом влияют на звучание слогов.

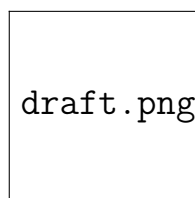


Рис. 3: dakut\_sample

- Кандзи (см. Рис. 4). Это символы, несущие семантическую нагрузку. С точки зрения написания иероглифы можно поделить на пиктограммы, идеограммы и фонограммы **TODO: ?**.

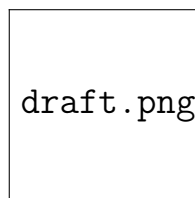


Рис. 4: kandji\_sample

Кана различает 46 слогов, которые могут записываться как катаканой, так и хираганой. А вот иероглифов кандзи существует гораздо больше (6000 достаточно для жизни, а стандарт Unicode определяет 21000) **TODO: цифры.**

Японский текст записывается с помощью комбинаций кандзи, кан и пунктуации, при этом отсутствует пробельное деление предложений на слова (см. Рис. 5).

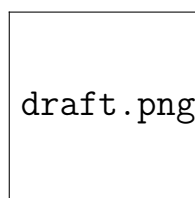



Рис. 5: japtext

По сравнению с латино-романскими языками, где алфавит меньше в сотни раз, а деление текста на слова очевидно, задача корректного распознавания символов становится значительно сложнее. Это требует более изощрённых подходов для автоматического анализа распознанного текста и поиска ошибок в нём.


Рассмотрим несколько примеров символов, которые легко спутать.

## 1.2 Путающиеся символы в японском


2Кана 2 похожие каны. Таким случаев достаточно мало, а методы их различения уже существуют.



KaGa Кана может легко путаться с соответствующим её дакутен-символом.



BigSmall Существуют большие и маленькие каны, которые нужно различать.



TODO: HalfWidth?

### 1.3 Формальная постановка задачи

**Определение 1.3.1.** *Алфавит*  $\Sigma = \{a, b, c, \dots\}$  – множество символов в данном языке. В японском языке их около 80000, стандарт Unicode поддерживает примерно 21000.

**Определение 1.3.2.** *Текст*  $Text \in \Sigma^+$  – последовательность символов из алфавита  $\Sigma$  положительной длины.

**Определение 1.3.3.** Текст делится на конечное множество *предложений*  $S = \{S_1, S_2, S_3, \dots\}$  знаками пунктуации и форматированием.  $Text = S_1 S_2 S_3 \dots$

Для каждого из предложения текста существует единственно верный вариант написания **TODO: а что делаем с омонимией?**, а также некоторое (фиксированное) число неверных. Требуется ответить, какой из вариантов верен.



**Определение 1.3.4.** *Оценивающий алгоритм (estimator)  $\Theta : S \rightarrow \mathbb{R}^+$  – функция, возвращающая оценку правильности варианта  $S$ .*

Среди  $k$  вариантов предложения выбирается наилучший:  $S_{best} = \operatorname{argmax}_S \Theta(S)$ , который и считается правильным.

Если  $S_{best}$  угадано верно, то на данном предложении алгоритм  $\Theta$  отработал правильно.

**Определение 1.3.5.** *Качество алгоритма  $Q(\Theta) = \frac{\#\{\text{угаданных предложений}\}}{\#\{\text{всего предложений}\}}$ .*

Задача – реализовать ряд оценивающих алгоритмов (см. раздел 3), основанных на  $n$ -граммных моделях, и сравнить их по качеству.

## 2 Обзор источников

TODO: includelitreview

- Banerjee.
- Nagata - actual
- Nagata - old

## 3 Описание моделей оценивания текста

Перед обучением моделей корпус разбивается на независимые и гомогенные части: обучающую и тестовую выборки. Обучающая выборка используется для обучения модели, тестовая – для проверки качества обучения и, собственно, оценки модели.

В работе рассматриваются следующие модели:

- $n$ -граммные с фиксированным  $n$ ,  $n \in \{1, 2, 3\}$
- Вскофф-модель,  $n_{max} \in \{3, 5, 7\}$
- Модель Катца (Katz),  $n_{max} \in \{3, 5, 7\}$

Также из-за большого размера алфавита необходимо использовать сглаживание (smoothing) для учёта символов и  $n$ -грамм, не встретившихся в обучающей выборке. Подробнее о механизме сглаживания – см. раздел 4.

### 3.1 $N$ -граммные модели с фиксированным $n$

**Обучение модели** Для данного  $n$  по обучающей выборке собираются статистики по всем  $n$ -граммам. Эти статистики затем нормализуются и сериализуются для дальнейшего использования.

$$C(x_{i-n+1}, \dots, x_{i-1}, x_i)$$

**Применение модели** В силу простоты модели оценка  $n$ -граммы из тестовой выборки берётся напрямую из собранных на предыдущем этапе статистик.

$$P(x_i | x_{i-n+1}, \dots, x_{i-1}) = C(x_{i-n+1}, \dots, x_{i-1}, x_i)$$

## 3.2 Backoff-модель

**Обучение модели** Этап обучения модели практически такой же, как и в случае простой  $n$ -граммной модели, с разницей в том, что здесь собираются статистики для всех  $n \leq n_{max}$ .

**Применение модели** Идея backoff-подхода состоит в том, что при нехватке данных для оценки какой-либо  $n$ -граммы  $x_{i-(n-1)} \dots x_{i-1} x_i$  постепенно уменьшается  $n$ , что позволяет увеличить общность алгоритма и оценить  $n$ -грамму по частям, но более надёжно. За счёт этого уменьшается вероятность переобучения модели на конкретных данных. [TODO: link](#)

$$P_n(x_i | x_{i-n+1}, \dots, x_{i-1}) = \begin{cases} C(x_i | x_{i-n+1}, \dots, x_{i-1}) & \text{if } C(x_i | x_{i-n+1}, \dots, x_{i-1}) > k \\ P_{n-1}(x_i | x_{i-n+2}, \dots, x_{i-1}) & \text{otherwise} \end{cases}$$

## 3.3 Модель Катца (Katz)

**Обучение модели** Этап обучения модели такой же, как и в случае backoff-модели.

**Применение модели** Модель Катца является улучшенной версией backoff-модели, в которой накладывается динамический дисконт (коэффициенты  $d_{w_{i-n+1} \dots w_i}$  и  $\alpha_{w_{i-n+1} \dots w_{i-1}}$ ) на оценку  $n$ -граммы в случае уменьшения  $n$ . Более подробно о модели Катца можно прочитать в [TODO: link](#)

$$P_n(w_i | w_{i-n+1} \dots w_{i-1}) = \begin{cases} d_{w_{i-n+1} \dots w_i} \frac{C(w_{i-n+1} \dots w_i)}{C(w_{i-n+1} \dots w_{i-1})} & \text{if } C(w_{i-n+1} \dots w_i) > k \\ \alpha_{w_{i-n+1} \dots w_{i-1}} P_{n-1}(w_i | w_{i-n+2} \dots w_{i-1}) & \text{otherwise} \end{cases}$$

[TODO: Рассказать про коэффициенты](#)

## 3.4 [TODO: Maybe Kneser-Ney](#)

## 4 Описание эксперимента

Для исследования способов исправлять ошибки OCR в тексте необходимо либо иметь большой корпус размеченных данных с результатами распознавания, либо как-то выкручиваться.

Пришлось выкручиваться, эмулируя ошибки OCR самостоятельно.

### 4.1 **TODO: Описание машины – надо ли?**

### 4.2 Корпус

Для обучения и сравнения  $n$ -граммных моделей использовался корпус html-страниц с ряда японских сайтов (**TODO: Каких? Где?**) общим размером  $\approx 8,5GB$ .

Тексты из этого корпуса не были результатом OCR, поэтому в них не должно было быть ошибок, связанных с распознаванием. Эти тексты были признаны верными с точки зрения языка и подходящими для обучения моделей.

В рамках подготовки корпуса к эксперименту тексты были перемешаны, чтобы тематика текста не зависела от его исходного положения в корпусе, из текстов были удалены html-теги, сложное форматирование, небольшое число мусорных символов. Также корпус был единообразно переведён в кодировку Unicode. Подробнее об этих технических этапах – см. раздел 5.

После вышеперечисленных операций корпус был готов к использованию, его размер составлял  $\approx 1,5GB$ . При этом размер алфавита в нашем корпусе составлял  $\approx 7000$  символов, что в 3 раза меньше размера таблиц Unicode.

Имея данные, готовые к использованию, было бы глупо не построить по ним несколько графиков.

### 4.3 **TODO: Zipf**

Если посмотреть на распределение частот отдельных символов, то оно выглядело так:

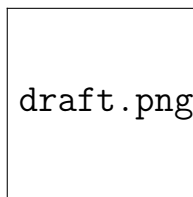


Рис. 6: 1gramstats

Видно, что распределение похоже на обратно экспоненциальное (кстати, это же утверждает закон Ципфа **TODO: link**). Проверим эту гипотезу, построив график обратного логарифма (**TODO: формулы**):

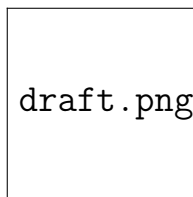


Рис. 7: zipf

Действительно, этот график с достаточной точностью ложится на прямую (**TODO: погрешности?**). Тем самым, в NLP закон Ципфа проверен ещё раз.

Посмотрев на Рис. 6, можно также заметить, что только очень малая часть символов появляется большое число раз. Посмотрим поближе на "голову" того же распределения:

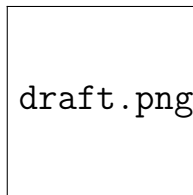


Рис. 8: 1gramstats head

Действительно, лишь  $\approx 200$  символов встречаются достаточно часто.

Остались ещё примерно 6500 символов, которые входят в алфавит, но статистически мало отличаются от тех символов, что вовсе не встретились в нашем корпусе. Для оптимизации времени работы и занимаемой памяти эти символы можно представить более сжато.

**Определение 4.3.1.** *Корзина (bucket, bucket)* – множество символов, которые считаются статистически малозначимыми и заменяются на U+FFFD (Unicode Replacement Character).

Бакет  $B_i$  характеризуется числом  $|\Sigma_{B_i}|$  – размером алфавита, который остаётся после сливания некоторого хвоста распределения в бакет. Было решено рассматривать бакеты с алфавитами размером  $|\Sigma_{B_i}| = \{\}$

## 4.4 Генератор шума и режимы его работы

**Определение 4.4.1.** *Шум Noise* =  $\{(a_1, a_2), (b_1, b_2, b_3), (c_1, c_2), \dots\}$  – множество наборов символов алфавита  $\Sigma$ , которые легко спутать при распознавании. Конкретные шумы определяются эмпирически.

С помощью шума *Noise* случайным образом генерируются ошибки в предложениях текста *Text*. Таким образом происходит стохастическая эмуляция ошибок OCR.

Поскольку нам были недоступны корпуса текстов, распознанные какой-либо OCR машиной, было принято решение симулировать ошибки OCR самим. Тестовая часть корпуса была разбита на предложения (см. формальную постановку задачи), которые независимо друг от друга зашумлялись.

Для данного шума ( Ka-Ga, HalfWidth, BigSmall, Mix ) выбирались индексы символов в предложении, которые затем случайно менялись на какой-то из своего множества.

Были определены следующие шумы:

**TODO: Примеры**

- KaGa
- HalfWidth

- BigSmall
- Mix

TODO: Примеры зашумлённого текста

## 4.5 Baseline

TODO: Вспомнить про Baseline, и как мы его считали.

## 4.6 Пример работы и статистик

TODO: Разобрать предложение и пройти по этапам визуализации результата (до svg-картинки с траем).



## 5 Реализация модели

### 5.1 nltk, Python, избранные куски кода в приложении?

## 6 Результаты эксперимента

Сравнение моделей для различных шумов, циферки.

## 7 Анализ результатов

## 8 Заключение

# Литература

- [1] *Soumendu Das et al.* Survey of Pattern Recognition Approaches in Japanese Character Recognition // (IJCSIT) International Journal of Computer Science and Information Technologies, Vol. 5(1), 2014. P. 93 - 99.
- [2] *Nagata, Masaaki* Japanese OCR Error Correction using Character Shape Similarity and Statistical Language Model // Proceedings of the 17th International Conference on Computational Linguistics - Volume 2, 1998. P. 922 - 928.
- [3] *Nagata, Masaaki* Context-based Spelling Correction for Japanese OCR // Proceedings of the 16th Conference on Computational Linguistics - Volume 2, 1996. P. 806 - 811.
- [4] Pygtrie documentation [Электронный ресурс].  
URL: <http://pygtrie.readthedocs.io/en/latest/> – 2014